1. Bölüm Teorik Temeller (Fonem Modelleme) Çözümü

Konuşma tanımada her kelime, fonem adı verilen ses birimlerinden oluşur ve HMM'de bu fonemler Hidden States olarak temsil edilir. "EV" kelimesini tanıyan modelimiz için tanımlanan parametreleri matematiksel olarak ifade ederek başlayalım:

Parametreler:

- Gizli durumlar uzayı (S) → $S = \{e, v\}$
- Gözlem Uzayı (O) → $O = \{High, Low\}$
- Gözlem Dizisi (Y) → $Y = [Y_1, Y_2] = [High, Low]$
- Başlangıç olasılıkları (π): Sistemin "e" durumunda başladığı kesin olarak verilmiştir.

$$\pi_e = P(e) = 1.0$$
$$\pi_v = P(v) = 0.0$$

- Geçiş Olasılıkları Matrisi (A)
  - $P(e \to e) = 0.6$, $P(e \to v) = 0.4$
  - $P(v \to v) = 0.8$, $P(v \to e) = 0.2$

- Emisyon Olasılıkları Matrisi (B): Belirli bir gizli bir durumdayken ilgili gözlemin üretilme ihtimaliden
  - e durumundayken: $P(High|e) = 0.7$, $P(low|e) = 0.3$
  - v durumundayken: $P(High|v) = 0.1$, $P(low|v) = 0.9$

Adım 1 $t = 1$

İlk zaman adımında mikrofondan gelen gözlem $Y_1 =$ High olarak ölçülmüştür.
Bu adımda, her bir durumda olma olasılığımızı, başlangıç olasılığımızla ile o durumun High gözlemini üretme olasılığını çarparak buluruz.

$$V_1(k) = \pi_k \times b_k(y_1)$$

'e' durumu:

$$V_1(e) = P(e) \times P(High|e)$$

$$V_1(e) = 1.0 \times 0.7 = 0.7$$

Anlamı = Sistem %100 "e" ile başlar ve "e"nin High frekansını üretme ihtimali %70'tir. Bu nedenle şu anki maksimum olasılığımız 0.7'dir

'v' durumu:

$$V_1(v) = P(v) \times P(High|v)$$
$$V_1(e) = 0.0 \times 0.1 = 0.0$$

$\Rightarrow$ Sistem 'v' durumunda başlayamaz bu yüzden olasılık 0'dır.

$t = 1$ anındaki en olası yollar.

- 'e' ye varan en iyi yol [e]
- 'v' ye varan en iyi yol [v]

Adım 2 Recursion - Zaman $t=2$

y_2 = Low olarak ölçülmüştür. Viterbi algoritması bu adımda her bir durum ('e', 'v') için, bir önceki adımdaki en iyi yollardan hangisinin daha yüksek olasılıkla bu duruma geleceğini hesaplar.

$$V_t(k) = \max_{x \in S} V_{t-1}(x) \times a_{xk} \times b_k(y_t)$$

Hedefiniz 'e' durumunda olmak ve Low gözlemini üretmek. 2 farklı yerden 'e'ye gelebilirsiniz.

1. Önceki durum 'e' ise:

$$V_1(e) \times P(e \to e) = 0.7 \times 0.6 = 0.42$$

2. Önceki durum 'v' ise:

$$V_1(v) \times P(v \to e) = 0.0 \times 0.2 = 0.0$$

Bu geçişlerden max'ı alıyoruz ve bunu 'e'nin Low üretme olasılığı ile çarpıyoruz:

$$V_2(e) = 0.42 \times P(\text{Low} \mid e)$$
$$= 0.42 \times 0.3 = 0.126$$

'e' durumuna gelen en olası yol, önceki adımı 'e' olan yoldur yeni yol: [e, e]

Hedefimiz 'v' durumunda olmak ve Low gözlemini üretmek. Yine 2 farklı yerden 'v' ye gelebiliriz.

1. 'e'den : $V_1(e) \times P(e \to v) = 0.7 \times 0.4 = 0.28$

2. 'v'den : $V_1(v) \times P(v \to v) = 0.0 \times 0.6 = 0.0$

max = 0.28 ve bunu $P(low | v)$ ile çarpalım.

$$V_2(v) = 0.28 \times P(Low | v)$$
$$= 0.28 \times 0.9 = 0.252$$

$\Rightarrow$ 'v' durumuna gelen en olası yol, önceki adımı 'e' olan yoldur. Yeni yol [e, v]

Adım 3 Termination

Gözlem dizimiz [High, Low] sonlandığı için en son zaman adımı olan t=2 'de elde ettiğimiz maksimum yolları karşılaştırıyoruz.

$V_2(e) = 0.126$
$V_2(v) = 0.252$

$V_2(v) > V_2(e)$ olduğu görülmektedir. Bu da demek oluyor ki, bu gözlem dizisini üretme ihtimali en yüksek olan nihai durum 'v' dir.

Backtracking yapıldığında, 'v' durumuna en yüksek olasılıkla 'e' den gelindiği tespit edildi.

[High, Low]'u üreten en olası fonem dizisi [e, v]

HMM Speech Recognition 3. Bölüm Analiz ve Yorumlama Cevapları

Ahmet Yusuf Pazarlıoğlu 23291203

Soru 1 : Ses verisindeki "gürültü" (noise), HMM modelindeki Emisyon Olasılıklarını nasıl etkiler?

Cevap 1: Gizli Markov Modellerinde (HMM) emisyon olasılıkları (yayılma olasılıkları), sistem belirli bir gizli durumdayken (örneğin 'e' fonemi), belirli bir gözlemin (örneğin yüksek frekans) üretilme ihtimalini, yani $P(O_t | S_j)$ değerini ifade eder. Ses verisine giren çevresel gürültü (noise), mikrofon tarafından ölçülen akustik sinyalin (ve dolayısıyla çıkarılan özniteliklerin) varyansını artırır. Bu durumun model üzerindeki matematiksel ve yapısal etkileri şunlardır:

- Olasılık Dağılımının Düzleşmesi (Flattening): İdeal ve temiz bir ses kaydında, bir fonemin belirli bir frekans bandını üretme olasılığı çok keskindir (örneğin, $P(High | e) = 0.9$ ve $P(Low | e) = 0.1$). Gürültü eklendiğinde, sinyalin karakteristiği bozulduğu için model bu net ayrımı yapamaz hale gelir. Keskin olasılık dağılımları tekdüze (uniform) bir dağılıma yaklaşır (örneğin, gürültülü ortamda bu değerler 0.55 ve 0.45 seviyelerine kayabilir).
- Ayırt Ediciliğin (Discriminative Power) Düşmesi: Emisyon olasılıklarındaki bu düzleşme, farklı gizli durumların benzer gözlemler üretme ihtimalini artırır. Viterbi algoritması en olası yolu hesaplarken emisyon olasılıklarını çarpan olarak kullandığından, gürültü nedeniyle yanlış bir fonemin skoru, doğru fonemin skoruna çok yaklaşabilir veya onu geçebilir. Bu da doğrudan kelime tanıma hata oranını (Word Error Rate) artırır.
- Sinyal-Gürültü Oranı (SNR) Problemi: Eşleşme (matching) aşamasında, eğer eğitim verisi (temiz ses) ile test verisi (gürültülü ses) arasındaki SNR farkı yüksekse, modelin önceden öğrendiği emisyon matrisi (B) test koşullarını yansıtmayacağı için modelin genelleme yeteneği çöker.

Soru 2: Gerçek bir sistemde binlerce kelime olduğunu düşünürsek, Viterbi yerine neden daha karmaşık yapılar (Deep Learning gibi) tercih edilmeye başlanmıştır?

Cevap 2: İzole bir kelime tanıma sistemini, sözlüğünde binlerce kelime bulunan sürekli konuşma (continuous speech recognition) sistemlerine genişlettiğimizde, HMM ve Viterbi algoritması yapısal darboğazlara girer. Derin öğrenme mimarilerinin (RNN, LSTM, Transformer tabanlı modeller) bu noktada tercih edilmesinin temel nedenleri şunlardır:

- Durum Uzayı Patlaması (Curse of Dimensionality) ve Hesaplama Maliyeti: Viterbi algoritmasının zaman karmaşıklığı $O(T \times |S|^2)$ formülü ile ifade edilir (T zaman adımı sayısı, $|S|$ ise gizli durum sayısıdır). Binlerce kelimelik bir sözlükte, her kelimenin kendi fonem dizisi ve bu fonemler arası geçişler (triphone modellemesi vb.) düşünüldüğünde durum uzayı $|S|$ devasa boyutlara ulaşır. Bu durum, Viterbi'nin gerçek zamanlı (real-time) çözümleme yapmasını hesaplama maliyeti açısından imkansız hale getirir.
- Markov Varsayımının Yetersizliği: HMM, doğası gereği "Birinci Dereceden Markov Varsayımı"na dayanır. Bu varsayım, mevcut durumun sadece bir önceki duruma bağlı olduğunu kabul eder. Ancak insan dili ve konuşması uzun vadeli (long-term) anlamsal ve sözdizimsel bağlamlar içerir. Derin öğrenme modellerindeki dikkat mekanizmaları (Attention) ve hafıza hücreleri, cümledeki çok daha eski bağlamları hatırlayarak akustik ve dil modellemesini çok daha başarılı yapar.
- Otomatik Öznitelik Çıkarımı ve Uçtan Uca (End-to-End) Öğrenme: HMM tabanlı sistemlerde MFCC gibi özniteliklerin manuel olarak çıkarılması ve akustik model ile dil modelinin ayrı ayrı eğitilmesi gerekir. Derin öğrenme yapıları ise ham ses dalgalarını veya spektrogramları alıp karmaşık hiyerarşik özellikleri (örneğin Evrişimli Sinir Ağları - CNN ile) doğrudan öğrenebilir ve tek bir mimari içinde uçtan uca optimize edilebilir.